Predicción de puntos en Fórmula 1

Machine Learning con información disponible antes de la carrera

Natalia Puñal | Data Science II

Modelado predictivo: 2010–2020

Abstracto, motivación y audiencia

¿Por qué predecir puntos antes de una carrera?

- **Motivación:** la clasificación y el rendimiento histórico permiten estimar parcialmente los puntos esperados.
- **Objetivo:** transformar resultados históricos en una predicción interpretable antes de la largada.
- **Audiencia:** analistas deportivos, medios, plataformas de estadísticas y fanáticos.
- **Alcance:** el modelo no elimina la incertidumbre de abandonos, clima, estrategia o fallas mecánicas.

Datos y metadata

Resumen del conjunto utilizado para el modelado

Fuente principal	Kaggle: resultados de carrera y clasificación
Fuente complementaria	API Jolpica: calendario, circuito, país, fecha y ronda
Dataset final	4,609 filas y 12 columnas en df_modelado
Variable objetivo	Points
Predictores	7 numéricos y 3 categóricos
Partición temporal	2010–2018 / 2019 / 2020

Preguntas e hipótesis

Preguntas que orientan el análisis y la construcción del modelo

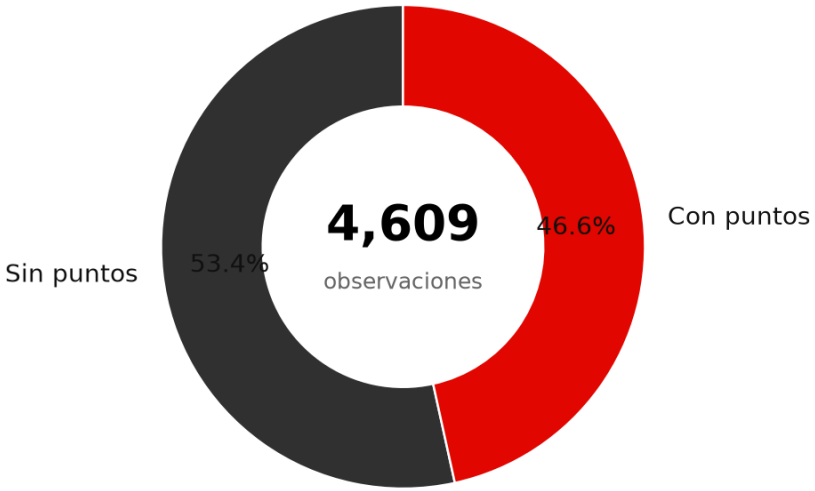
Pregunta principal: ¿En qué medida la clasificación y el desempeño histórico permiten estimar los puntos que obtendrá un piloto?

- ¿Cómo se distribuyen los puntos obtenidos por los pilotos?
- ¿Qué relación existe entre la posición de clasificación y los puntos?
- ¿Qué variables aportan mayor capacidad predictiva?
- ¿El modelo supera una predicción basada en el promedio histórico?
- **Hipótesis:** Random Forest supera al baseline y a Ridge en datos futuros.

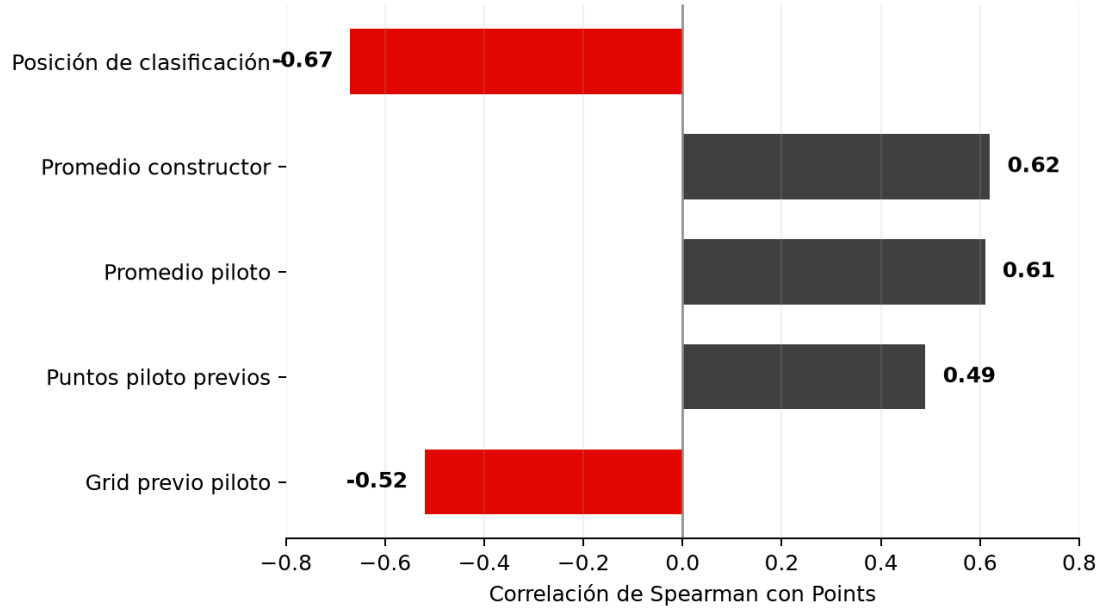
Visualizaciones ejecutivas: distribución y clasificación

La grilla de salida es la señal individual más fuerte

Distribución de la variable objetivo



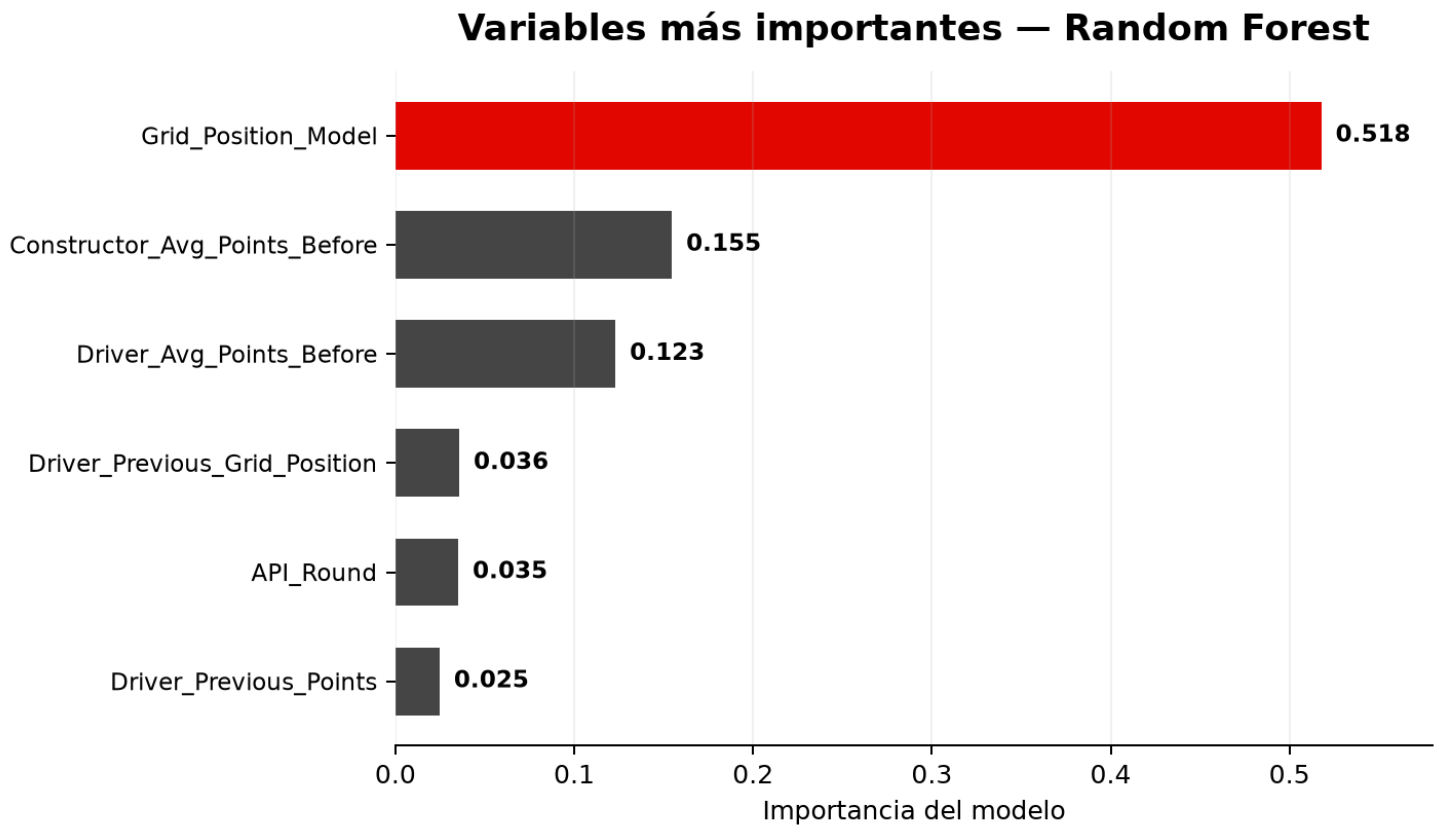
Variables con mayor relación con los puntos



- 53.44% de los registros no obtuvo puntos.
- La correlación de Spearman entre grilla y puntos fue -0.67.

Factores predictivos

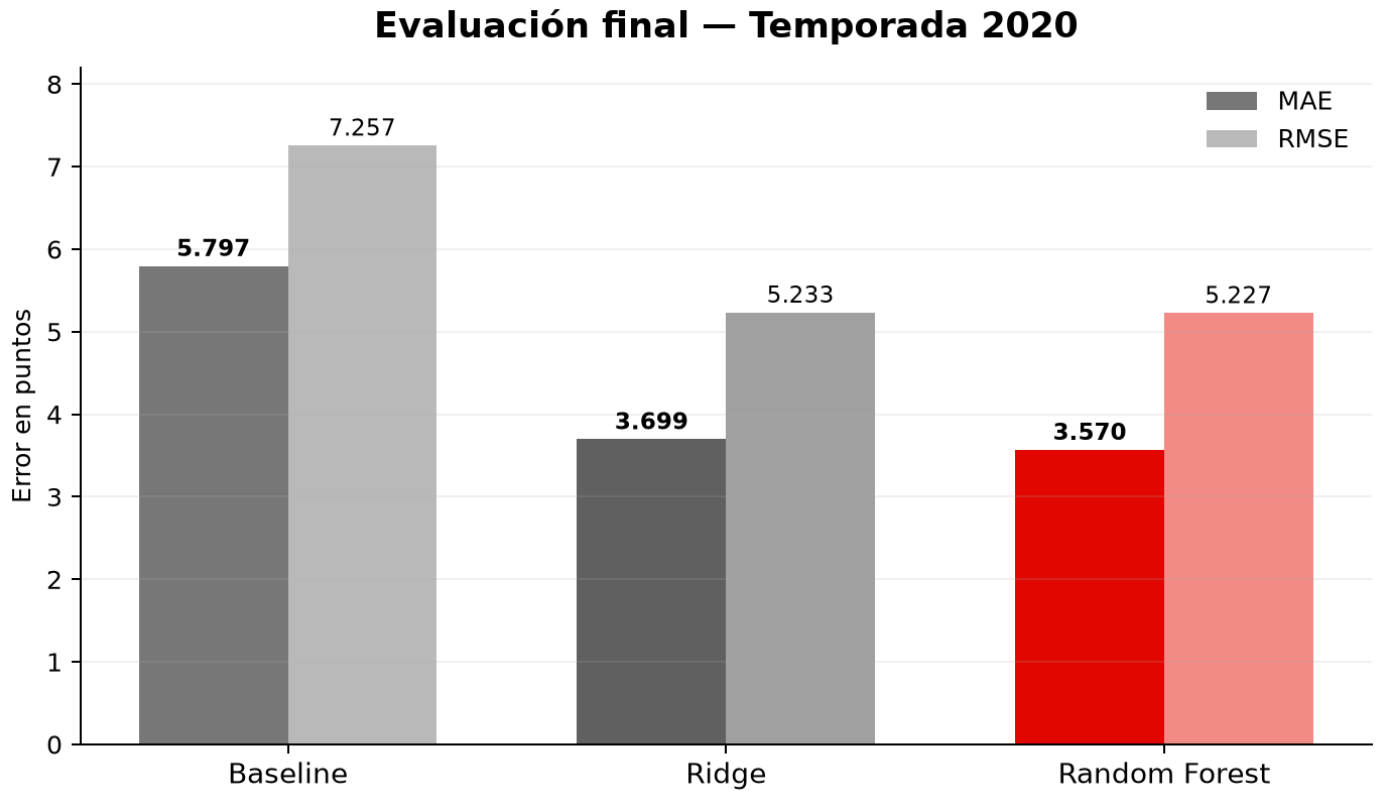
Importancia de variables en el Random Forest final



- La posición de clasificación concentra el 51.8% de la importancia total.
- El desempeño histórico del constructor pesa más que el promedio histórico del piloto.
- Ronda, carrera previa y circuito complementan el pronóstico.

Evaluación del modelo

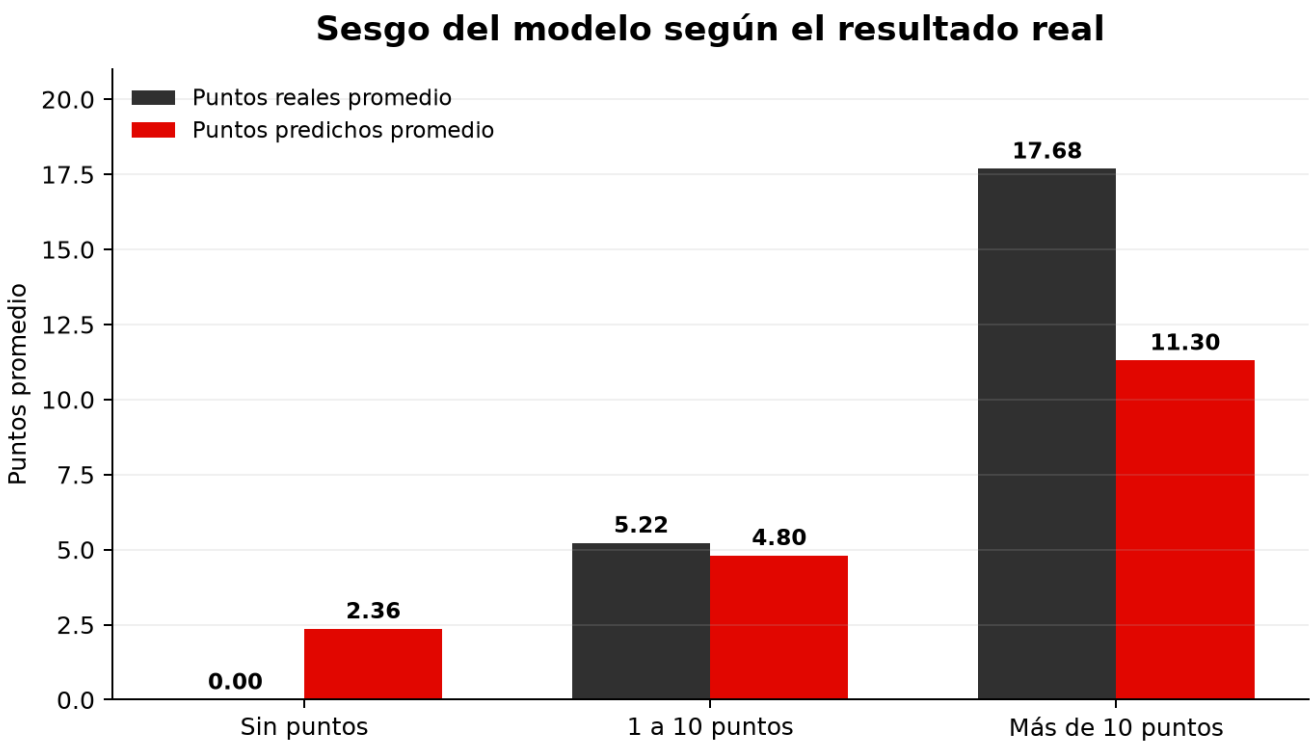
Entrenamiento 2010–2018 · Validación 2019 · Prueba final 2020



- Random Forest fue seleccionado por obtener el menor MAE en validación 2019.
- En 2020 obtuvo MAE = 3.570, RMSE = 5.227 y R^2 = 0.480.
- Redujo el MAE en 38.4% frente al baseline.

Insights, limitaciones y cierre

El modelo es útil como estimación previa, no como resultado exacto



- Sobreestima pilotos que terminan sin puntos: 2.36 puntos predichos en promedio.
- Subestima resultados altos: 11.30 puntos predichos frente a 17.68 reales.
- Limitaciones: no incluye abandonos, accidentes, clima, estrategia, sanciones ni fallas mecánicas.
- Mejora futura: modelo en dos etapas para probabilidad de puntuar + cantidad de puntos.